

危險性機械雙 AI 引擎架鋼印 防偽辨識系統研究

陳宜左

【摘要】本研究針對危險性機械鋼印防偽提出「雙 AI 引擎特徵交叉辨識系統」。傳統拓印方式易受油污、鏽蝕與光線影響，缺乏量化標準。研究結合 Vision API 的幾何量測與 Gemini 3.1 的語意推理，透過遷移學習與特徵交叉建立五維決策空間，成功區分真品與高仿樣本。實驗顯示，Gemini 在字元辨識率達 95.8%，優於 Vision 的 73.2%。系統設計「星級防偽評等」與「LEVEL 分級標準」，確立 Y 軸誤差與傾斜度為防偽核心指標。採用無伺服器架構與提示詞工程，確保現場即時判定與報表生成。研究貢獻包括量化鋼印幾何邊界、首創雙引擎交叉協作流程，並提出未來以照片取代紙本拓印、AR 智慧眼鏡整合等應用展望。

【關鍵詞】危險性機械、防偽辨識、雙 AI 引擎、遷移學習、Vision API。

壹、前言

一、研究背景與實務需求

危險性機械（如起重機、鍋爐、壓力容器等）在各國工業安全法規中均屬於高風險管控設備。為確保設備與申報資料一致，防止「同號碼、不同機台」之舞弊現象，檢驗員必須在現場進行「鋼印核實」。傳統方式為

使用碳粉或鉛筆對鋼印進行「拓印（Rubbing）」，隨後與歷年照片或銘牌進行肉眼比對。然而，拓印紙常因油污、生鏽或打光角度導致資訊不對稱[1]，極度仰賴檢驗員之「資深度」，缺乏可追溯的量化科學標準。

二、相關技術回顧與 AI 導入困境

目前的電腦視覺技術（Computer

Vision) 雖在字元辨識 (OCR) 領域已臻成熟，但面對「鋼印防偽」時卻面臨以下三大瓶頸：

(一) 跨媒材雜訊

拓印 (2D 墨跡) 與實體照片 (3D 凹痕) 在像素分佈上完全不同，傳統 CNN 模型極難在兩者間建立直接映射。

(二) 樣本稀缺性

真實的「變造樣本」數據取得不易，導致自訓練模型常因負樣本不足而產生過度擬合 (Overfitting) [2]。

(三) 幾何幻覺

許多大型視覺模型 (LMM) 雖具備語意理解力，但在精密測量 (毫米級間距) 上常產生數據幻覺。

三、比較通用模型與自訓練模型的優缺點

在系統開發初期，本研究針對 AI 模型架構之選擇進行了深入評估，主要考量為「自訓練專屬模型 (Custom-Trained Model)」與「大型通用多模態模型 (General Multimodal LMMs)」兩條路徑：

(一) 自訓練模型 (如 YOLOv8 結合 CRNN)

(1) 優點：針對特定字體或乾淨背景，

可達到極高的準確率與極快的運算速度，且可完全在地化部署。

(2) 缺點：訓練此類模型需要極大量的「標記資料集 (Annotated Data)」。

由於危險性機械所處環境極端惡劣 (嚴重鏽蝕、油漆剝落、打光不均)，且廠牌字模繁多，蒐集並標註數萬張帶有瑕疵的鋼印照片成本過於高昂；且若遇到未曾見過的生僻字型，模型容易產生嚴重誤判 (Overfitting)。

(二) 大型通用多模態模型 (如 Google Gemini 3.1)

(1) 優點：具備強大的「零樣本學習 (Zero-shot Learning)」能力與常識推理能力。不需額外訓練，即可直接理解「生鏽」、「反光」、「疊影」等物理現象，並具備極佳的容錯與視覺腦補能力。[3]

(2) 缺點：仰賴雲端 API 呼叫，且模型輸出的結果較難以精準的數學數值量化。

考量檢驗機構的開發資源與現場極端多變的鋼印樣本，本研究提出雙軌併行之解決路徑：利用「遷移學習」引入現有強大 AI 的視覺常識，並透過「特徵交叉」強制融合數學幾何與語意邏輯。

貳、核心技術架構(遷移學習與特徵交叉)

一、遷移學習 (Transfer Learning) 的應用

本研究不再嘗試從零訓練專屬權重，而是採用 Google Vision API 與 Gemini 3.1 作為骨幹。這是一種「模型級遷移」：

(一) 低階特徵遷移

利用 Vision 引擎成熟的邊緣檢測 (Edge Detection) 能力，穩定提取字元邊界框座標。就像是扮演「虛擬游標卡尺」，專職量測字元的幾何座標。計算拓印與實體照片的 X 軸間距誤差、Y 軸高低誤差與相對傾斜度 (Tilt Angle)。

(二) 高階語意遷移

藉由 Gemini 3.1 模型在千億級圖像訓練中學到的「常識推理」，讓其扮演「資深檢查員之眼」，專職進行微觀物理特徵的推理。判斷字型筆畫是否一致 (Char_Match)、深淺與疊影特徵是否合理 (Feat_Match)。

此架構成功解決了單一模型無法兼顧「精準數學量測」與「複雜視覺推理」的難題。

二、特徵交叉 (Feature Crossing) 的決策模型

在機器學習中，單一特徵（如純語意辨識或純邊緣檢測）往往難以處理非線性之複雜分類問題。實務上，高仿變造的鋼印可能在「字元內容」上完全合法，卻在「打刻深度」或「微觀間距」上露出破綻。

為此，本系統導入特徵交叉原理，將 Vision 引擎提取之連續型幾何特徵 (X 軸間距誤差、Y 軸高低誤差、傾斜度) 與 Gemini 引擎提取之離散型語意特徵 (字元吻合度、物理特徵吻合度) 進行多維度融合。在系統底層，這兩類特徵被封裝為一個高維度的鑑定特徵向量 (Feature Vector) V ：

$$V = [E_X, E_Y, E_\Theta, S_{\text{char}}, S_{\text{feat}}]^T$$

透過組合這些統計上相互獨立 (正交) 的變數，系統成功創造出一個五維的決策空間。在此特徵交叉矩陣中，原本在低維度下難以區分的「高仿變造鋼印」與「正常生鏽鋼印」，其特徵向量將被強行拉開，從而產生極度清晰的線性可分邊界 (Linearly Separable Boundary) [4]，使系統得以落實「一維度異常即一票否決」的嚴格防偽機制。

(一) 正常模式 (Vision 成功取得幾何數據) (表 1)

(二) 降級救援模式 (Vision 因影像過糊無法量測)

表 1 正常模式 (Vision 成功取得幾何數據)

星級	定義與後續動作	觸發條件
★★★★★ 5 星：完全沒問題	完美吻合，現場可直接放行。	1.幾何 Level 0 2.字元 Pass & 特徵 Pass
★★★★ 4 星：略有誤差可接受	幾何受拍攝變形影響略有偏移，但特徵完美，安全可放行。	1.幾何 Level 1 2.字元 Pass & 特徵 Pass
★★★ 3 星：需人工覆核	數據落在模糊地帶，不放行也不退件，強制要求檢驗員開啟手動疊影確認。	1.幾何達 Level 2 邊緣 2.或 字元判為 Doubt 3.或 特徵判為 Doubt
★★ 2 星：非常有問題	高低間距、傾斜度嚴重異常或特徵矛盾。高風險為「同號碼不同設備」。	1.幾何完全走鐘(Level 3) 2.或特徵有明確矛盾(Fail)
★ 1 星：完全不符合	一票否決！AI 判定字元內容有異，極可能為造假或拍錯設備，直接退件。	字元判為 Fail

當拓印或實體影像品質過低，導致系統無法取得幾何座標時，系統會啟動安全降級機制，最高僅能給予 3 星，並強制回歸人工判斷。若為 3 星，代表字元與特徵皆通過，AI 認為外觀正確但無法計算尺寸，因此需人

工覆核；若為 2 星，則表示標籤不一致或出現疑慮，影像過於模糊且 AI 也判斷有問題；若為 1 星，則代表字元與特徵皆不符合，雖然無法量測尺寸，但 AI 已辨識出字根本不同。

這樣的設計確保在影像品質不足

時，系統能以分級方式提示風險，並交由人工判斷補強，避免誤判。

參、實驗設計(測試集與驗證集之建構)

本研究建立兩大實驗庫，用以校準系統之 LEVEL 標準：

一、測試集 (Positive Set / Ground Truth)

共收集 60 組真實對應樣本。每組包含該設備之「標準拓印」與現場拍攝之「原始實體鋼印」（如圖 1）。此集合代表了物理世界中受相機角度、曲面形變干擾下的「合理變量邊界」。此集合皆使用人工逐一確認拓印與鋼印是完全符合，並排除少數連人類都無法判斷的樣本。



圖 1 鋼印與拓印(本圖為 AI 產出示意圖)

二、驗證集 (Negative Set / Adversarial Samples)

共收集 20 組近似比對樣本。實驗設計採用「號碼尾數不符」（如圖 2）之真實樣本。此集合旨在測試系統的

「報警敏感度」，模擬惡意竄改之情境。



圖 2 號碼尾數不符的鋼印與拓印(本圖為 AI 產出示意圖)

肆、結果評估與空間幾何拓樸之線性迴歸與邊界界定

本項為本研究確立 AI 系統「LEVEL 分級標準」之核心數學論證。本研究將測試集（60 組真值）與驗證集（20 組變造值）之最大誤差數據進行了分佈對比與線性迴歸分析。

一、兩大 AI 引擎之字元辨識成功率 (Recognition Rate)

針對 60 台測試集設備，統計兩引擎對於 10 碼設備編號之辨識完整度(表 2)：

分析評估：數據顯示 Gemini 3.1 在分辨能力上具備顯著優勢，即便影像極其模糊，仍能透過上下文判讀出號碼；反觀 Vision 引擎常因拓印中的一個污點而導致字元邊界框斷裂，且因過嚴格的判讀會導致字元的辨識錯

誤，不過因將字元辨識工作交由 Gemini 3.1 處理，Vision 只需判讀出整體字元邊界並加以計算 X 軸、Y 軸及傾斜度即可，故仍能保有 73.2%的準確可用率。

因辨識需兩項同時都分辨出來才可以進行，整體辨識成功率降為 73.2%(Gemini 3.1 未能分辨出的，

Vision API 同樣也無法辨識)。

二、測試集 (Ground Truth) 之幾何物理極限

在 60 筆確認為真品的集合中，數據展現了極其強烈的規律性（如圖 3）：

表 2 兩大 AI 引擎之字元辨識成功率

引擎	成功分辨字數(平均)	成功率(%)	失敗/剔退原因分析
Vision API	7.3 字元	73.2 %	極度依賴邊緣對比，常受碳粉污點干擾。
Gemini 3.1	9.6 字元	95.8 %	強大的視覺腦補與語意預測能力，容錯度極高。




圖 3 測試集結果分布圖

(一) X 軸（水平間距）誤差分佈

由於相機拍照時的視角傾斜（透視變形）影響，X 軸展現了較大的寬容度。平均誤差為 4.32%，而 99%的極端樣本收斂於 8.5%以內。

(二) Y 軸（垂直高低）誤差分佈

這是本研究最驚人的物理發現。

無論相機如何歪斜，Y 軸的高低起伏與中心點連線幾乎免疫於光學透視變形。95%真品樣本，Y 軸最大誤差皆小於 1.5%，呈現極度陡峭的收斂常態分佈。

(三) 180 度傾斜反轉現象：

推測可能是類型體字造成 Vision 引擎判斷顛倒，導致傾斜度 (Tilt) 出現 179 度之極端值。經由 $\text{abs}(180 - \text{tilt})$ 之模數校正演算法後，所有真品的傾斜角誤差皆小於 2.0 度。

三、驗證集 (Adversarial) 之特徵表現

在 20 筆「號碼尾數不符」的驗證集中，偽造樣本在交叉空間中無所遁形。即便變造者刻意敲出與拓印相同的號碼字串（躲過語意引擎），但因

為人類手工打刻困難複製前次的微觀力道與間距，其空間特徵呈現出顯著表現：

(一) X 軸最大間距誤差往往超過 12.0%~18.0%。

(二) Y 軸最大高低誤差則跳升至 5.0%~9.0%。

四、迴歸分析與「決策真空斷層」之確立

將測試集與驗證集繪製於同一 X-Y 散佈圖，並對測試集進行線性迴歸 (Linear Regression) 分析 (圖 4)：




圖 4 線性迴歸 (Linear Regression) 分析

- (一) 正交性證明：測試集的線性迴歸 R2 值趨近於 0.000 (p-value>> 0.05)。這證明了「間距誤差」與「高低誤差」是兩個完全獨立正交的物理變數，進一步證實了採用「特徵交叉」多維度防護網的絕對必要性。
- (二) 完美邊界(The Decision Margin): 圖表中顯示，代表真品的藍色叢集(Cluster)與代表偽造品的紅色散點之間，存在一個極度寬廣且清晰的幾何斷層。真品的 Y 軸

極限為 3.0%，而偽造品的 Y 軸起跳值幾乎都在 5.0%以上。

五、 VISION LEVEL 判定標準之學術確立

基於上述堅實的統計斷層，本研究正式確立並量化了本防偽系統的核心決策矩陣(The Level Standards)。此矩陣採用非對稱閾值(放寬 X，極度收緊 Y 與 Tilt)，實現了零誤殺與極高攔截率的完美平衡(表 3)：

表 3 VISION LEVEL 判定標準

防偽級別	X 軸 (最大間距)	Y 軸 (最大高低)	最大傾斜角	物理邊界意義與系統行動
Level 0 (極度吻合)	≤5.0%	≤1.5%	≤1.0 度	落於測試集核心常態分佈。[AI 自動放行]
Level 1 (合理變形)	≤8.5%	≤3.0%	≤2.0 度	涵蓋光學透視之物理容忍邊界。[AI 自動放行]
Level 2 (大偏移極限)	≤12.0%	≤5.0%	≤4.0 度	跨越真品極限，進入斷層邊緣。[強制人工覆核]
Level 3 (完全走鐘)	>12.0%	>5.0%	>4.0 度	完美落入驗證集偽造分佈區。[一票否決/退件]

依據測試集結果，本研究對 Vision 引擎設定了「合理辨識門檻」，Vision 必須至少成功抓取 6 個字元以

上，其幾何運算方具備統計意義。因低於 5 個字元時，幾何正規化(Normalization)的基準線容易因單

一離群值而產生劇烈偏差。高於 6 字元時，幾何向量空間趨於穩態，足以支撐精確比對。

伍、系統實作與應用展示

為驗證本研究所提出之「雙引擎特徵交叉防偽架構」之可行性，本研究捨棄了封閉的黑箱系統，採用開源且輕量化的架構進行實作。本章節將詳細闡述系統的軟體佈署與運算邏輯，以利後續研究者進行學術驗證與復刻

一、無伺服器系統架構設計

考量到檢驗機構之資訊維護成本與資料安全性，本系統揚棄傳統的地端伺服器架構，全面採用輕量化、高彈性的無伺服器（Serverless）雲端架構[5]進行佈署：

（一）前端使用者介面（Frontend - GitHub Pages）

系統前端以輕量化的 HTML/JavaScript 進行開發，並託管於 GitHub Pages。此設計不僅具備極高的連線可用性與零維護成本，檢驗員亦可輕易透過任何行動裝置（平板或手機）開啟網頁介面，符合現場檢驗之機動性需求。

（二）後端邏輯與資料庫（Backend -

Google Apps Script, GAS)

後端運算核心建置於 Google Apps Script (GAS) 環境中，作為 API 閘道 (Gateway)，僅負責影像之編碼轉發、雙引擎運算調度與結果解析，並安全地呼叫 Google Cloud Vision API 與 Gemini 3.1 模型進行雙引擎運算。此外，系統內建了嚴密的 API 金鑰遮罩 (Key Masking) 與逾時自動接力 (Continuation Token) 機制，確保大批次處理時的系統穩健度與資訊安全。

二、雙引擎提示詞工程實作 (Prompt Engineering)

在導入 Gemini 3.1 作為副引擎時，本研究發現，若僅輸入未經修飾的指令，模型極易因拓印紙的物理雜訊而產生過高的「誤殺率 (False Reject Rate)」，因此，本系統實作了嚴謹的「提示詞工程 (Prompt Engineering)」，賦予模型專業的檢查員視角。

系統在每次呼叫 API 時，皆會向模型注入以下核心系統指令 (System Instruction)：

（一）角色賦予

定義模型為「資深的工業鋼印防偽分析師」，使其判讀邏輯趨向嚴謹且具備工業常識。

(二) 導入物理寬容原則

於提示詞中明文宣告拓印的物理特性：「拓印紙因鉛筆塗抹，字體必定比實體略粗、邊緣模糊。且常因施力不均導致 8 拓成 3，0 拓成 C。若遇此類合理視覺混淆，請判定為 Doubt，不可直接判 Fail。」此一指令成功將資深檢驗員的「隱性知識（Tacit Knowledge）」轉化為 AI 可執行的決策邏輯。

(三) 強制結構化輸出

要求模型將判讀結果以嚴格的 JSON 格式回傳（包含 Char_Match、Feat_Match、Reason 以及模型還原之 Text_Rubbing 雙向字串），使後端程式能精準擷取語意特徵，並與幾何特徵進行交叉運算。

三、實務查驗介面與自動化報表展示

為確保檢驗任務的直覺性與現場適用性，本研究開發之系統介面設計以「原始影像輸入」與「即時特徵比對」為核心。系統操作流程嚴格遵循現場檢驗之自然邏輯：

(一) 影像擷取與感興趣區域（ROI）鎖定

檢查員透過行動裝置開啟前端網頁，依序匯入現場拍攝之實體鋼印照

片與拓印影像。為使 AI 引擎能精準定位運算範圍，系統提供直覺化之手勢操作工具，允許檢驗員直接於原圖上縮放並框選出「感興趣區域（Region of Interest, ROI）」。此步驟之目的在於定義座標運算之邊界，系統並不對原始影像進行任何去噪、二值化或像素修補，以確保後續幾何分析係基於最真實的現場數據（如圖五）。（介面保留原始設計針對影像前處理後在上傳之功能，非在本次研究範圍內）



圖五 鋼印及拓印實際操作介面(方塊為去識別化處理)

(二) 跨平台 API 調度與運算 (Cross-platform API Dispatching)：

當檢查員完成區域框選後，系統前端即透過加密通訊協議（HTTPS），將選定區域之影像原始資料傳送至後端 Google Apps Script（GAS）閘道。後端程式隨即並行驅動 Vision 幾何引擎與 Gemini 語意副引擎，分別針對

原始影像之像素座標與物理外觀進行深度特徵提取。

(三) 即時判定與分析結果產出 (Instant Evaluation and Reporting)：

比對運算完成後，系統會即時將分析結果回傳至前端介面（如圖六）。檢驗員可立即查閱由系統決策矩陣產出之「防偽星級評等 (Star Rating)」。該評分綜合了原始幾何誤差與 AI 語意推理結果，並輔以具體的判定說明。此一「原圖即時比對」機制，確保了檢驗數據的原始性與不可篡改性，並大幅縮短了現場設備核實所需的時間。圖五中的「本機檢驗紀錄(歷史回顧)」資料僅保留在該行動裝置之瀏覽器中。



圖六 判定結果產出(方塊為去識別化處理)

陸、結論與建議

一、研究貢獻

(一) 驗證遷移學習 (Transfer Learning) 於工業冷啟動場景之優越性

本研究證實透過大型多模態模型的遷移學習，無需海量標註數據，即可有效解決工業現場因樣本稀缺、拓印環境惡劣（如鏽蝕、反光、碳粉量染）所導致的辨識困境。

(二) 界定鋼印打刻之絕對幾何物理邊界

透過 60 筆測試集與 20 筆驗證集的嚴格對照，本研究量化確立了 Y 軸位移與傾斜度誤差 (Tilt) 是比號碼字符串內容更具防偽公信力的指標，成功找出真偽樣本間的幾何斷層。

(三) 首創雙引擎特徵交叉協作流程

建立以 Vision API 執行「高精度空間測量」與 Gemini 3.1 執行「宏觀語意感知」的雙軌架構。透過特徵交叉 (Feature Crossing) 機制，達成語意與幾何的互補，大幅降低了誤殺率與漏網率。

二、未來展望與應用落地

(一) 從「通用」走向「專用」：模型微調 (Fine-tuning) 之優化路徑

本研究目前採用的遷移學習技術

雖已展現極高準確度，但未來可進一步利用本研究累積之實證數據作為基礎，對模型進行監督式微調（Supervised Fine-tuning, SFT）或採用 LoRA（Low-Rank Adaptation）技術。

- (1) 字型領域適應：針對台灣工業設備常用的 CNS 標準鋼印字體、特種打刻字模進行深度微調，強化模型對特定筆畫比例與深度特徵的敏感度。
- (2) 噪聲抗性強化：針對極端生鏽、多層防鏽漆覆蓋等特定工業噪聲場景進行微調，使模型能更精準地從破碎的像素中重建特徵，進一步降低目前約 27% 的系統剔退率。

(二) 檢驗媒材之典範轉移：由 Photo-to-Photo 取代紙本拓印

實驗顯示，紙本拓印的物理限制是目前技術瓶頸的主因。未來建議推動作法變更，將傳統「留存紙本拓印」之規範，改為「數位高解析照片存查」。透過演算法直接進行「照片對照片（Photo-to-Photo）」的精密幾何比對，預期能將幾何量測準確度提升至 98% 以上。

(三) 硬體載具與工作流程之數位化

- (1) AR 穿戴裝置整合：未來可將本系

統整合至智慧眼鏡（Smart Glasses），檢驗員只需視線掃描，系統即可即時完成特徵交叉與邊界判定，排除手動拍照與上傳的操作摩擦力，實現真正的「解放雙手（Hands-free）」智慧檢驗。

- (2) 制度轉型支援：藉由本研究之量化數據作為佐證，建議檢驗機構逐步建立鋼印幾何特徵資料庫，將原本流於主觀的肉眼判斷，轉化為客觀、可追溯、具備法律證據力（Forensic level）的科學決策流程

按：陳宜左*

* 中華產業機械設備協會代行檢查員。

參考文獻

- [1] Zheng, Y., Li, H., & Wang, J. (2020). Industrial text detection and recognition based on deep learning: A review. *Measurement*, 166, 108201.
- [2] Ren, Z., Fang, F., Yan, N., & Wu, Y. (2022). State of the Art in Defect Detection Based on Machine Vision. *International Journal of Precision Engineering and Manufacturing-Green Technology*, 9(2), 661-691.
- [3] Jeong, J., Zou, Y., Kim, T., Zhang, D., & Kweon, I. S. (2023). WinCLIP: Zero-/Few-Shot Anomaly Classification and

-
- Segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 19606-19616).
- [4] Cheng, H. T., Koc, L., Harmsen, J., Shaked, T., Chandra, T., Aradhye, H., ... & Shah, E. (2016). Wide & deep learning for recommender systems. In Proceedings of the 1st workshop on deep learning for recommender systems (pp. 7-10).
- [5] Castro, P., Ishakian, V., Muthusamy, V., & Slominski, A. (2019). The rise of serverless computing. *Communications of the ACM*, 62(12), 44-54.
- [6] Google Cloud. (2024). Cloud Vision API Documentation. Retrieved from <https://cloud.google.com/vision/docs>
- [7] Google DeepMind. (2024). Gemini 1.5 Pro and Flash API Documentation. Retrieved from <https://ai.google.dev/docs> 